



**Universidad
de Concepción**

Universidad de Concepción
Facultad de Ingeniería
Departamento Ingeniería Civil Informática

Proyecto Semestral: Métricas de centralidad en redes

Asignatura: Estructuras de Datos

Grupo 10: Ariel Cisternas, Agustín Salgado, Ignacio Silva

Profesor: José Fuentes

Enlace repositorio: <https://github.com/elamiql/Proyecto-Semestral-ED.git>

Concepción, 22 de junio de 2026

Índice

1. Introducción	2
2. Representación y Medidas de Centralidad	2
2.1. Representación del Grafo	2
2.2. Medidas de Centralidad Base	3
2.2.1. Degree Centrality (In/Out-degree)	3
2.2.2. Betweenness Centrality	4
2.2.3. Closeness Centrality	5
2.2.4. PageRank	6
2.2.5. Average Shortest Path	6
3. Medidas de Centralidad Adicionales	7
3.1. Local Clustering Coefficient	7
3.2. Network Diameter	7
4. Análisis Teórico (Peor Caso)	8
4.1. Construcción del Grafo	8
4.2. Complejidades de las Métricas	8
5. Metodología y Entorno Experimental	8
5.1. Entorno de Ejecución	8
5.2. Diseño Experimental	9
5.3. Descripción de los Conjuntos de Datos	9
5.3.1. IMDb Actors Dataset	9
5.3.2. Network IoT Dataset	9
5.4. Detalles de Implementación	9
6. Resultados Experimentales y Análisis	10
6.1. Rendimiento Base	10
6.2. Tiempos de las Medidas	10
6.2.1. IoT Network	10
6.2.2. IMDb Actors Network	10
6.3. Sensibilidad de la Red	11
6.3.1. IoT Network	11
6.3.2. IMDb Actors Network	11
7. Conclusiones	12
8. Referencias	13

1. Introducción

El análisis de redes complejas permite comprender el comportamiento de sistemas interconectados, desde interacciones biológicas hasta infraestructuras de telecomunicaciones. En la teoría de grafos, una red se modela como un conjunto de vértices V y aristas E , donde $G = (V, E)$. Ciertos elementos estructurales poseen un grado de importancia crítico; por ejemplo, identificando cuellos de botella en la congestión de datos o zonas vulnerables en un sistema.

El objetivo de este proyecto es implementar, analizar y contrastar diversas métricas de centralidad: Degree Centrality, Betweenness Centrality, Closeness Centrality, PageRank, Average Shortest Path, Local Clustering Coefficient y Network Diameter. Estas medidas permiten caracterizar la importancia relativa de los vértices, la conectividad global de la red y la eficiencia con que la información se propaga a través del sistema.

Para evaluar la eficiencia de estas métricas, el estudio contempla un diseño experimental sobre conjuntos de datos reales de naturaleza diversa, analizando además la sensibilidad de la red frente a la adición o eliminación de conexiones.

Para ello, se implementó un ADT Grafo basado en una lista de adyacencia extendida con tabla hash, lo que permite manejar de forma flexible y eficiente en memoria los identificadores de texto presentes en los datasets utilizados. Los resultados obtenidos muestran que las métricas basadas en caminos mínimos (Betweenness, Closeness, Average Shortest Path y Network Diameter) constituyen el principal cuello de botella computacional del sistema, mientras que ambas redes analizadas evidenciaron una resiliencia topológica considerable frente a perturbaciones locales.

2. Representación y Medidas de Centralidad

2.1. Representación del Grafo

Se implementó el ADT Grafo utilizando una Lista de Adyacencia extendida con una tabla hash. Esta decisión responde a que los vértices de los datasets analizados (IMDb Actors y Network IoT) son cadenas de texto, no índices numéricos continuos.

La estructura usa un mapa bidireccional para traducir en tiempo constante cada identificador de texto a un índice numérico interno $(0, 1, \dots, V-1)$. Las aristas se almacenan en un `std::vector<std::vector<Edge>>`. Esta representación es flexible para grafos dirigidos y no dirigidos, y eficiente en memoria para redes dispersas.

Algoritmo de Construcción: El grafo se construye de manera incremental a partir de la lectura secuencial del dataset. Para cada registro (origen, destino, peso) se consulta el mapa hash; si el identificador no existe, se le asigna un nuevo índice y se reserva su posición en la lista de adyacencia. Luego, se agrega la arista correspondiente mediante un `push_back` sobre el vector de adyacencia del nodo origen (y también del destino, en caso de tratarse de un grafo no dirigido).

Algorithm 1 Construcción Incremental del Grafo

```

1: procedure CONSTRUIRGRAFO(dataset)
2:   for cada registro (origen, destino, peso) en dataset do
3:     if origen  $\notin$  mapaID then
4:       mapaID[origen]  $\leftarrow$  nuevoIndice
5:       nuevoIndice  $\leftarrow$  nuevoIndice + 1
6:       adyacencia.push_back(lista vacía)
7:     end if
8:     if destino  $\notin$  mapaID then
9:       mapaID[destino]  $\leftarrow$  nuevoIndice
10:      nuevoIndice  $\leftarrow$  nuevoIndice + 1
11:      adyacencia.push_back(lista vacía)
12:    end if
13:    adyacencia[mapaID[origen]].push_back(Edge(mapaID[destino], peso))
14:    if grafo no dirigido then
15:      adyacencia[mapaID[destino]].push_back(Edge(mapaID[origen], peso))
16:    end if
17:  end for
18: end procedure

```

Este procedimiento concuerda con la complejidad temporal $O(|V| + |E|)$ detallada en la Sección 4.1, dado que cada inserción de vértice y arista se realiza en tiempo amortizado constante.

2.2. Medidas de Centralidad Base

2.2.1. Degree Centrality (In/Out-degree)

Definición: El Degree Centrality cuantifica la importancia de un nodo a partir del número de conexiones directas que mantiene con otros nodos de la red, representando así su influencia local. En términos conceptuales, esta métrica parte del supuesto de que un nodo con una mayor cantidad de enlaces posee una mayor capacidad para poder interactuar, influir o intercambiar información con su entorno inmediato.

En grafos dirigidos, se subdivide en dos variantes: in-degree (aristas entrantes), que contabiliza la cantidad de conexiones que llegan al nodo y out-degree (aristas salientes) que representa el número de conexiones que parten desde él. Esta diferenciación resulta muy útil para modelar sistemas donde las relaciones poseen una dirección definida, como por ejemplo las redes sociales, de citación o enlaces entre páginas web.

Es importante mencionar que una limitación de esta métrica es que únicamente considera conexiones inmediatas y no toma en cuenta la posición estructural del nodo dentro de la red completa, haciendo así que en ocasiones un nodo pueda presentar un elevado grado de conexión sin necesariamente desempeñar un papel estratégico en la transmisión global de información.

Fórmula: Sea $G = (V, E)$ un grafo con $n = |V|$ nodos, el Degree Centrality de un nodo v se obtiene como:

$$C_D(v) = \deg(v)$$

donde $\deg(v)$ corresponde al número de aristas incidentes del nodo v . Para la comparación entre redes de distinto tamaño se utiliza la versión normalizada:

$$C'_D(v) = \frac{\deg(v)}{n-1}$$

Ejemplo: En una red social de 3 personas (A, B, C) donde A sigue a B y a C, el nodo A tiene out-degree 2, mientras que B y C tienen in-degree 1.

Complejidad: $O(1)$ por nodo; $O(|V| + |E|)$ en total para grafos dirigidos donde se calcula el in-degree globalmente.

Aplicación: En redes de interacción proteína-proteína, un alto grado indica una proteína estructuralmente esencial cuya eliminación puede ser letal para la célula.

2.2.2. Betweenness Centrality

Definición: La Betweenness Centrality mide el grado en que un nodo actúa como puente dentro de una red, evaluando cuántos de los caminos mínimos existentes entre todos los pares de nodos atraviesan dicho nodo. Esta métrica parte de la idea de que los procesos de propagación, ya sea información, recursos, influencia o enfermedades, suelen modelarse utilizando rutas mínimas. En consecuencia, un nodo con un elevado Betweenness Centrality posee una mayor capacidad para controlar el flujo de información entre diferentes regiones de la red.

A diferencia del Degree Centrality, esta métrica no depende del número de conexiones directas, haciendo posible que un nodo tenga relativamente pocos vecinos y, aun así, presentar una elevada importancia si constituye el único enlace entre dos comunidades o grupos altamente conectados internamente.

Fórmula: Sea $G = (V, E)$ un grafo con $n = |V|$ nodos, v un nodo cualquiera, σ_{st} el número de caminos mínimos entre s y t , y $\sigma_{st}(v)$ el número de esos caminos mínimos que pasan por el nodo v :

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

La versión normalizada para grafos no dirigidos es:

$$C'_B(v) = \frac{2C_B(v)}{(n-1)(n-2)}$$

Para grafos dirigidos:

$$C'_B(v) = \frac{C_B(v)}{(n-1)(n-2)}$$

Ejemplo: En una red donde dos grupos solo se conectan a través de un nodo central (peaje), ese nodo tiene betweenness máximo. Su eliminación divide la red en dos componentes aislados.

Complejidad: Se implementó el Algoritmo de Brandes. En grafos sin peso usa BFS: $O(|V| \cdot (|V| + |E|))$. En grafos ponderados usa Dijkstra: $O(|V| \cdot (|V| + |E|) \log |V|)$.

Aplicación (IoT): Un router con alto betweenness es un punto crítico de vulnerabilidad; su caída puede aislar subredes enteras.

2.2.3. Closeness Centrality

Definición: El Closeness Centrality mide qué tan próximo se encuentra un nodo respecto del resto de nodos de la red. Matemáticamente, se define como el inverso de la suma de las distancias mínimas desde un nodo hacia todos los demás nodos alcanzables. Esta métrica refleja la eficiencia con la que un nodo puede acceder al resto de la red. Un nodo con alto Closeness Centrality puede transmitir información, recursos o influencia hacia otros nodos utilizando un menor número promedio de pasos, lo que lo convierte en un punto privilegiado para la difusión rápida de información.

A diferencia del Degree Centrality, el Closeness Centrality considera la estructura completa de la red, ya que incorpora las distancias geodésicas entre nodos, entendidas como la longitud del camino más corto que conecta dos nodos dentro de la red. Por ello, un nodo con pocas conexiones directas puede presentar un elevado Closeness Centrality si se encuentra estratégicamente ubicado cerca del centro topológico de la red.

Es importante decir que esta métrica presenta limitaciones en redes desconectadas, ya que las distancias infinitas dificultan su cálculo. Para solucionar este problema suelen emplearse variantes basadas en la media armónica de las distancias.

Fórmula: Sea $G = (V, E)$ un grafo con $n = |V|$ nodos, v un nodo cualquiera, $d(v, u)$ la longitud del camino mínimo entre los v y u .

$$C_C(v) = \frac{1}{\sum_{u \neq v} d(v, u)}$$

Y la versión normalizada:

$$C'_C(v) = \frac{n-1}{\sum_{u \neq v} d(v, u)}$$

Ejemplo: En una fila de personas, quien está en el centro puede susurrar un mensaje a los extremos con menos intermediarios que cualquier otro.

Complejidad: $O(|V| \cdot (|V| + |E|) \log |V|)$ mediante Dijkstra desde cada vértice.

Aplicación (IMDb): Un actor con alto closeness puede conectar rápidamente distintos elencos o clústeres de la industria cinematográfica.

2.2.4. PageRank

Definición: PageRank es una métrica que evalúa la importancia de un vértice considerando no solo cuántas conexiones recibe, sino la importancia de los nodos que lo enlazan. Es un proceso iterativo donde la importancia se distribuye entre los vecinos salientes.

El algoritmo modela el comportamiento de un "navegante aleatorio" que recorre la red siguiendo enlaces con cierta probabilidad y, ocasionalmente, salta a un nodo aleatorio mediante un factor de amortiguamiento (damping factor). Como consecuencia, un nodo recibe una puntuación elevada cuando es referenciado por otros nodos que también poseen alta relevancia.

En comparación con otras métricas de centralidad, PageRank ofrece una visión más global de la importancia estructural de los nodos, considerando tanto conexiones directas como la calidad de las conexiones indirectas.

Fórmula:

$$PR(v) = \frac{1-d}{N} + d \sum_{u \in In(v)} \frac{PR(u)}{L(u)}$$

donde $d = 0,85$ es el factor de amortiguación, $In(v)$ los nodos que apuntan a v , y $L(u)$ el out-degree de u .

Ejemplo: Un investigador citado por pocos artículos muy influyentes tendrá mayor PageRank que uno citado por muchos artículos irrelevantes.

Complejidad: $O(K \cdot (|V| + |E|))$, donde K es el número de iteraciones hasta la convergencia.

Aplicación: En redes comerciales, un país no es importante solo por exportar a muchos, sino por exportar a países que son potencias económicas.

2.2.5. Average Shortest Path

Definición: La longitud promedio del camino más corto (Average shortest path length) es una métrica global de la red que representa el promedio de las distancias mínimas existentes entre todos los pares de nodos. No caracteriza un nodo individual sino la topología completa, reflejando el concepto de "mundo pequeño".

Esta medida describe el nivel de eficiencia con el cual la información, los recursos o cualquier tipo de flujo pueden desplazarse a través de la red. Valores bajos indican que los nodos se encuentran relativamente próximos entre sí, permitiendo comunicaciones rápidas y eficientes. Por el contrario, valores elevados reflejan redes más dispersas, donde la información requiere recorrer un mayor número de enlaces para alcanzar su destino.

Fórmula:

$$L = \frac{1}{n(n-1)} \sum_{i \neq j} d(v_i, v_j)$$

Ejemplo: Un ASP de 2.5 en una red corporativa significa que cualquier empleado puede contactar a otro con 2 o 3 intermediarios en promedio.

Complejidad: $O(|V| \cdot (|V| + |E|) \log |V|)$ mediante Dijkstra desde cada vértice.

Aplicación (IoT): Un ASP bajo indica que un malware puede propagarse por la red con muy pocos saltos.

3. Medidas de Centralidad Adicionales

3.1. Local Clustering Coefficient

Definición: El Local Clustering Coefficient mide la probabilidad de que los vecinos de un vértice estén conectados entre sí, indicando la densidad de comunidades locales. El coeficiente toma valores entre 0 y 1. Un valor igual a 1 indica que todos los vecinos del nodo están conectados entre sí, mientras que un valor cercano a 0 refleja que prácticamente no existen conexiones entre ellos.

Fórmula: Para un vértice i con grado k_i y e_i aristas entre sus vecinos:

$$C_i = \frac{2e_i}{k_i(k_i - 1)}$$

Ejemplo: Si un nodo tiene 4 vecinos y 3 de ellos se conocen entre sí (de 6 pares posibles), su coeficiente es $3/6 = 0,5$.

Complejidad: $O(|V| \cdot d_{\text{máx}}^2)$, donde $d_{\text{máx}}$ es el grado máximo de la red.

Aplicación (IMDb): Un coeficiente cercano a 1 indica grupos de actores que trabajan repetidamente juntos, formando comunidades muy cerradas.

3.2. Network Diameter

Definición: El Network Diameter es la distancia máxima entre cualquier par de vértices conectados en la red; representa el peor caso de separación topológica. Esta métrica proporciona una medida del tamaño topológico de la red y permite estimar el número máximo de pasos necesarios para conectar dos nodos cualesquiera mediante caminos mínimos.

Un Network Diameter reducido indica una red altamente conectada y eficiente, donde incluso los nodos más alejados pueden comunicarse mediante pocas conexiones intermedias. Por el contrario, un Network Diameter elevado refleja una estructura más extensa o menos conectada. En redes desconectadas, el Network Diameter puede considerarse infinito debido a que existen pares de nodos entre los cuales no existe ningún camino.

Fórmula:

$$D = \max_{u,v} d(u, v)$$

Ejemplo: En el metro de una ciudad, el diámetro es la ruta más larga entre las dos estaciones más alejadas entre sí.

Complejidad: $O(|V| \cdot (|V| + |E|) \log |V|)$ mediante Dijkstra.

Aplicación (IoT): El diámetro establece la latencia máxima posible entre los dos dispositivos topológicamente más alejados de la red.

4. Análisis Teórico (Peor Caso)

4.1. Construcción del Grafo

Complejidad Temporal: $O(|V| + |E|)$. La inserción de un vértice requiere una consulta al `std::unordered_map` en $O(1)$ amortizado. La inserción de una arista implica un `push_back` en $O(1)$. El proceso de lectura secuencial del dataset resulta en costo lineal total.

Complejidad Espacial: $O(|V| + |E|)$. El mapa hash y el vector inverso ocupan $O(|V|)$; la lista de adyacencia ocupa $O(|E|)$. Esto evita el costo de $O(|V|^2)$ de una matriz de adyacencia.

4.2. Complejidades de las Métricas

- **Degree Centrality:** $O(|V| + |E|)$ en grafos dirigidos (recorre aristas para calcular in-degree).
- **Betweenness Centrality:** $O(|V| \cdot (|V| + |E|))$ con BFS (grafos sin peso) y $O(|V| \cdot (|V| + |E|) \log |V|)$ con Dijkstra (grafos ponderados).
- **Closeness, Average Shortest Path y Network Diameter:** Comparten la complejidad $O(|V| \cdot (|V| + |E|) \log |V|)$ al ejecutar Dijkstra desde cada vértice.
- **PageRank:** $O(K \cdot (|V| + |E|))$, donde K es el número de iteraciones hasta convergencia.
- **Local Clustering Coefficient:** $O(|V| \cdot d_{\max}^2)$, donde $d_{\max}$ es el grado máximo de la red.

5. Metodología y Entorno Experimental

5.1. Entorno de Ejecución

Las pruebas se ejecutaron en un notebook con procesador Intel® Core™ i5-10300H @ 2.50 GHz, 16 GB de RAM, bajo Windows 11 Home versión 25H2.

5.2. Diseño Experimental

Para la medición de tiempos de ejecución, cada una de las 7 métricas se calculó de manera completa sobre la totalidad del grafo cargado en memoria (sin muestreo de nodos), repitiendo cada cálculo 10 veces consecutivas mediante `std::chrono::high_resolution_clock`. A partir de estas 10 mediciones se obtuvo el tiempo promedio, la varianza muestral (con corrección de Bessel, dividiendo por $n - 1$) y el coeficiente de variación, definido como $CV = (\sqrt{\text{varianza}}/\text{promedio}) \times 100$.

El uso de memoria se midió consultando el campo `VmRSS` de `/proc/self/status` bajo Linux, o mediante la función `GetProcessMemoryInfo` de la API Win32 (estructura `PROCESS_MEMORY_COUNTERS`) bajo Windows.

5.3. Descripción de los Conjuntos de Datos

5.3.1. IMDb Actors Dataset

Naturaleza: Red no dirigida con pesos.

Descripción: Modela colaboraciones entre actores. Cada vértice es un actor y cada arista indica participación conjunta en al menos una película. El peso (*Strength*) corresponde al número de películas en común.

Procesamiento: Se extrajeron los campos `From`, `To` y `Strength` del archivo CSV, descartando encabezados y metadatos.

5.3.2. Network IoT Dataset

Naturaleza: Red dirigida con pesos.

Descripción: Modela tráfico de red entre dispositivos IoT. Cada vértice es una dirección IP; las aristas indican flujo de conexión con peso igual a la duración de la misma.

Procesamiento: El parser detecta automáticamente los índices de columnas relevantes en el encabezado y descarta el resto, optimizando el tiempo de lectura.

5.4. Detalles de Implementación

El proyecto fue desarrollado en C++, con manejo de memoria acotado a $O(|V| + |E|)$. Las principales decisiones técnicas son:

- **Estructura Interna del Grafo:** Las conexiones se encapsulan en una estructura `Edge` que almacena el ID del nodo destino y el peso (1.0 por defecto).
- **Eliminación de Aristas:** La operación `removeEdge` usa `std::remove_if` con `lambda`, en tiempo $O(\text{grado}(u))$, sin reconstruir la estructura.

- **Módulo de Carga:** El espacio de nombres `GraphLoader` separa el parseo de datos de la lógica del grafo, con limpieza de espacios y saltos de línea para evitar vértices fantasmas.
- **Bifurcación Algorítmica por Pesos:** Las métricas basadas en caminos mínimos evalúan dinámicamente la topología mediante `hasUnitWeights`. En IMDb, el peso *Strength* varía según las películas en común; en IoT, los pesos son duraciones variables. Al detectar esta heterogeneidad, la implementación usa Dijkstra en ambos casos para garantizar la correctitud matemática.
- **Coefficiente de Variación (CV):** Se reporta $CV = (\sigma/\mu) \times 100$ para comparar la estabilidad de ejecución entre métricas de distinta escala temporal, ya que la varianza cruda no es comparable entre métricas de microsegundos y de minutos.
- **Parámetros de PageRank:** La implementación utiliza un factor de amortiguación $d = 0,85$, un máximo de 100 iteraciones y una tolerancia de convergencia de 1×10^{-6} como criterio de corte del proceso iterativo.
- **Base Bibliográfica de los Algoritmos:** La implementación de las métricas sigue las formulaciones descritas en las referencias bibliográficas citadas en la Sección 8 (Brandes, 2001, para Betweenness Centrality; Page et al., 1999, para PageRank; Freeman, 1977, para las medidas de centralidad), adaptadas a la estructura `Graph` propia del proyecto.

6. Resultados Experimentales y Análisis

6.1. Rendimiento Base

Cuadro 1: Tiempo de construcción y uso de RAM por dataset.

Dataset	Tipo	Nodos	Aristas	Tiempo (ms)	RAM (MB)
IMDb Actors Network	No dirigido	33.234	102.154	87.71	10.13
IoT Network	Dirigido	776	211.043	661.43	4.14

6.2. Tiempos de las Medidas

6.2.1. IoT Network

Los tiempos son bajos por la reducida cantidad de nodos, a pesar de la alta densidad de aristas.

6.2.2. IMDb Actors Network

Se refleja el costo esperado de $O(|V|(|V| + |E|) \log |V|)$ para las métricas basadas en caminos mínimos.

Cuadro 2: Tiempos de ejecución: IoT Network.

Métrica	Promedio (ms)	Varianza (ms ²)	CV (%)
Degree Centrality	0.2477	0.0009	12.2421
Betweenness Centrality	12.1157	0.1026	2.6435
Closeness Centrality	5.9194	0.0918	5.1199
PageRank	19.2782	0.2017	2.3298
Average Shortest Path	5.8962	0.0709	4.5145
Local Clustering Coeff.	4.9451	0.0024	0.9820
Network Diameter	5.5760	0.0102	1.8086

Cuadro 3: Tiempos de ejecución: IMDb Actors Network.

Métrica	Promedio (ms)	Varianza (ms ²)	CV (%)
Degree Centrality	0.0980	0.0012	35.9636
Betweenness Centrality	77714.3448	1033620.8967	1.3082
Closeness Centrality	54232.2764	51344.7971	0.4178
PageRank	20.3870	0.2835	2.6118
Average Shortest Path	54379.3337	1056328.2748	1.8900
Local Clustering Coeff.	98.6777	7.8755	2.8439
Network Diameter	54128.9743	75218.6889	0.5067

6.3. Sensibilidad de la Red

Se analiza el impacto en métricas globales y locales al eliminar o agregar aristas en nodos de distinto rol en la red. El nodo Hub corresponde al de mayor grado en la red; el nodo Periferia corresponde al de menor grado entre los nodos no aislados (excluyendo grado 0); y el nodo Medio se determina por su posición en el arreglo interno de vértices (índice $\lfloor n/2 \rfloor$), buscando el vértice no aislado más cercano a dicha posición en caso de que el nodo central tenga grado 0.

Para cada perturbación se toma una fotografía base (*snapshot*) del grado promedio, el PageRank promedio y el Local Clustering Coefficient promedio de toda la red. Luego se aplica la modificación (remover o agregar una arista), se vuelve a calcular el snapshot y se reporta la diferencia (Δ) respecto a la base. Tras cada medición, la arista modificada se restaura (o se elimina, en el caso de la arista agregada), de modo que cada perturbación se evalúa de forma independiente sobre la red original.

6.3.1. IoT Network

Nodos seleccionados: Hub (grado 61.633), Medio (grado 224), Periferia (grado 1).

6.3.2. IMDb Actors Network

Nodos seleccionados: Hub (grado 208), Medio (grado 3), Periferia (grado 1).

Cuadro 4: Perturbaciones: IoT Network.

Acción	Δ Degree	Δ PageRank	Δ Clustering
Eliminar arista (Hub)	$-4,925 \times 10^{-3}$	≈ 0	$+1,194 \times 10^{-7}$
Eliminar arista (Periferia)	$-4,925 \times 10^{-3}$	≈ 0	≈ 0
Eliminar arista (Medio)	$-5,650 \times 10^{-3}$	≈ 0	≈ 0
Agregar Hub $\leftrightarrow$ Peri	$-4,919 \times 10^{-3}$	≈ 0	$-1,162 \times 10^{-7}$

Cuadro 5: Perturbaciones: IMDb Actors Network.

Acción	Δ Degree	Δ PageRank	Δ Clustering
Eliminar arista (Hub)	$-1,811 \times 10^{-9}$	≈ 0	$-3,453 \times 10^{-7}$
Eliminar arista (Periferia)	$-1,811 \times 10^{-9}$	≈ 0	$+4,356 \times 10^{-8}$
Eliminar arista (Medio)	$-1,811 \times 10^{-9}$	≈ 0	$-2,006 \times 10^{-5}$
Agregar Hub $\leftrightarrow$ Peri	$+1,811 \times 10^{-9}$	≈ 0	$+3,008 \times 10^{-5}$

En ambos casos, las perturbaciones individuales generan variaciones marginales en Degree y PageRank, dado que estas métricas dependen de la estructura global de la red y no de aristas puntuales. Sin embargo, el Local Clustering Coefficient resulta consistentemente más sensible, en particular al agregar conexiones entre nodos de distinto rol (Hub-Periferia), lo que confirma que esta métrica captura cambios estructurales locales que las métricas globales no logran reflejar.

7. Conclusiones

La implementación del ADT Grafo mediante listas de adyacencia y tablas hash demostró ser eficiente en memoria, permitiendo cargar más de 200.000 aristas con apenas 4.14 MB de RAM, evitando el costo de $O(|V|^2)$ de una matriz de adyacencia.

Las métricas basadas en caminos mínimos (Betweenness, Closeness, Average Shortest Path y Network Diameter) constituyen el principal cuello de botella computacional, limitadas por $O(|V| \cdot (|V| + |E|) \log |V|)$. Evitar la reconstrucción redundante de estructuras internas en Dijkstra fue clave para mantener tiempos manejables.

Los experimentos de perturbación muestran que ambas redes son topológicamente resilientes: eliminar una arista individual genera un impacto global marginal en PageRank y Degree promedio. Sin embargo, el Local Clustering Coefficient sí reaccionó de forma cuantificable, en particular ante la adición de atajos artificiales, lo que confirma su sensibilidad a cambios en la estructura local del grafo.

En síntesis, los resultados obtenidos validan la pertinencia de la representación elegida para datasets de naturaleza heterogénea, y permiten identificar con claridad los puntos críticos de rendimiento del sistema. Como trabajo futuro, podría explorarse la paralelización de los algoritmos basados en Dijkstra (ejecutados de forma independiente desde cada vértice), con el objetivo de reducir el cuello de botella computacional observado en redes de gran escala como IMDb Actors Network.

8. Referencias

1. Brandes, U. (2001). A faster algorithm for betweenness centrality. *Journal of Mathematical Sociology*, 25(2), 163–177.
2. Hagberg, A. A., Schult, D. A., & Swart, P. J. (2008). Exploring Network Structure, Dynamics, and Function using NetworkX. *Proceedings of the 7th Python in Science Conference (SciPy2008)*, 11–15.
3. Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank Citation Ranking: Bringing Order to the Web*. Technical Report, Stanford InfoLab.
4. Juneja, A. (2024). IMDb Actors Network Dataset. Kaggle. Recuperado de <https://www.kaggle.com/datasets/aditijuneja/imdb-actors-network-dataset>
5. Ipad, A. (2024). Network IoT Dataset. Kaggle. Recuperado de <https://www.kaggle.com/datasets/amineipad/ioittt>
6. Borgatti, S. P. (2005). Centrality and network flow. *Social Networks*.
7. Freeman, L. C. (1977). A set of measures of centrality based on betweenness. *Sociometry*.
8. ScienceDirect Topics. Centrality Metric. <https://www.sciencedirect.com/topics/computer-science/centrality-metric>